

DEPARTAMENTO DE ECONOMÍA LABORATORIO DE ECONOMETRÍA: STATA 1ECO31

Sesión 2 Manipulación de Datos con ENAHO

Docente: Juan Palomino



Índice

1	Organización del Proyecto	5	Tipo y Formato de Variables	9	Ordenar Observaciones y Variables
2	Cargando Base de Datos	6	Manipulando Variables	10	Etiquetas
3	Traducir Base de Datos	7	Manipulando Observaciones	11	Guardar y Exportar
4	Explorando Variables	8	Borrar y Mantener Variables		



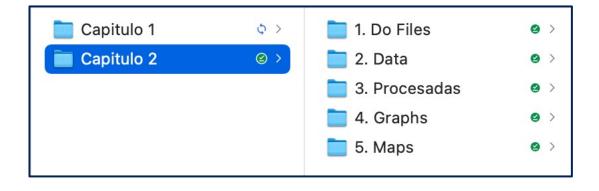
1. Organización del Proyecto



Criterios de Organización

¡Aprender a cómo organizar nuestros archivos de trabajo!.

Organizar información en carpetas



- Do Files: se guardan los do files de las programaciones.
- 2. Data: se guardan los archivos original de la data.
- **3. Procesadas:** se guardan las bases de datos procesadas a partir de los archivos originales.
- 4. Graphs: se guardan las figuras en png, gph, jpg.
- **5. Maps:** se guardan los archivos shapefiles.



Criterios de Organización

Una vez que hemos organizado nuestras carpetas, fijaremos la carpeta de trabajo donde estará nuestro proyecto actual con el comando "cd":

```
* Primera Opción
cd "/Users/juanpalomino/Google Drive/ENAHO/Sumaria"
```

También se puede guardar a través del comando "global" las rutas de las carpetas, y usarlas en los momentos apropiados:

```
* Segunda Opción
global main "/Users/juanpalomino/Google Drive/Cursos/Laboratorio de Stata"
global dos "$main/1. Do Files"
global dta "$main/2. Data"
global works "$main/3. Procesadas"
```



2. Cargando Base de Datos



Conceptualización de los Datos

Los datos deben estar presentados tal que las columnas sean las variables y las filas sus observaciones.

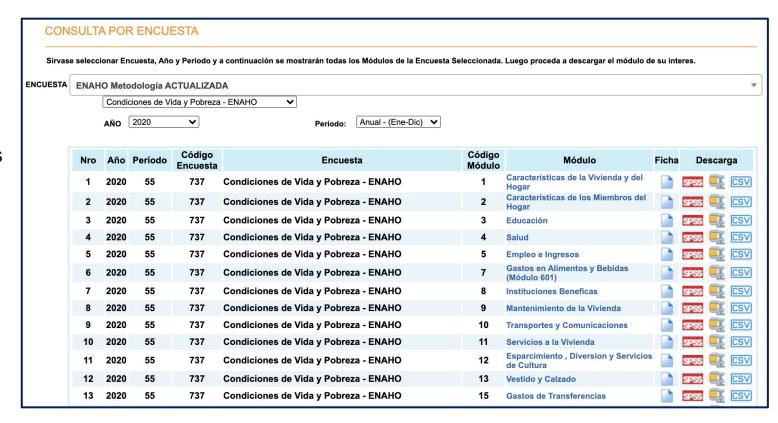
			Variables							
	_									
			conglome	vivienda	hogar	ubigeo	mieperho	inghog2d	gashog2d	pobreza
		1	005009	012	11	010101	2	37274.426	25065.797	no pobre
S		2	005009	041	11	010101	2	41967.57	28650.02	no pobre
one		3	005009	098	11	010101	6	42292.535	38136.219	no pobre
acic		4	005015	007	11	010101	4	37866.211	26812.154	no pobre
Observaciones	\dashv	5	005015	019	11	010101	4	91681.961	63311.539	no pobre
Se		6	005015	070	11	010101	4	29749.256	59986.023	no pobre
Ö		7	005015	085	11	010101	4	40505.797	33310.414	no pobre
		8	005015	117	11	010101	1	27953.023	21437.623	no pobre
		9	005032	014	11	010201	4	77708.43	38951.035	no pobre
		10	005032	047	11	010201	2	8458.1504	9408.3535	no pobre

Descargando Base de Datos

http://iinei.inei.gob.pe/microdatos/

Pasos:

- 1. Tipear <u>www.inei.gob.pe</u>
- 2. Clic en Bases de Datos y luego en Microdatos
- 3. Clic en Consulta por Encuestas
- 4. Escoger Enaho Metodología Actualizada
- 5. Elegir el año, periodo y el modulo de interés





Cargando Base de Datos

Stata tiene bases de datos predeterminadas en su memoria y estas se pueden abrir con el comando "sysuse"

```
* El comando sysuse
sysuse auto, clear
```

Si se quiere abrir un archivo de excel se usa "import excel":

```
* El comando import excel import excel "pwt100.xlsx", sheet("Data") firstrow clear
```

Para abrir una base de datos se usa el comando "use":

```
* El comando use
use "enaho01a-2020-500.dta", clear
```

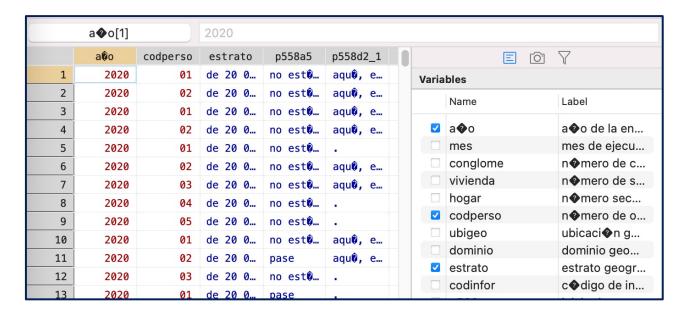


3. Traducir Base de Datos



Traducir Base de Datos

Problema: unicode o caracteres con signo de interrogación que no permiten leer adecuadamente la base de datos



Solución: usar el comando unicode para traducir la base de datos, pero para eso no se debe tener base abierta en Stata

```
clear all
unicode analyze "enaho01a-2020-500.dta"
unicode encoding set "latin1"
unicode translate "enaho01a-2020-500.dta"
```

Traducir Base de Datos

- **Primer Paso**: "unicode analyze" es para analizar si la base de datos contiene unicodes que se deben traducir a otro lenguaje.
- Segundo Paso: "unicode encoding set" es para establecer el lenguaje al cual se quiere traducir.
- **Tercer Paso**: "unicode translate" es para traducir la base de datos.

aÑo	codperso	estrato	p558a5	p558d2_1			
2020	01	Área de empadrona…	pase	aquí, en este distrito	Varia	bles	
2020	02	Área de empadrona…	no está afiliado	•		Name	Label
2020	03	Área de empadrona…	pase	en otro distrito		Name	Label
2020	04	Área de empadrona…	no está afiliado	•	✓	aÑo	año de la en
2020	01	Área de empadrona…	pase	en otro distrito		codperso	número de
2020	02	Área de empadrona…	no está afiliado	aquí, en este distrito	✓	estrato	estrato geo
2020	03	Área de empadrona…	no está afiliado		✓	p558a5	¿el sistema
2020	04	Área de empadrona	no está afiliado		✓	p558d2_1	el lugar don
2020	05	Área de empadrona	no está afiliado	aquí, en este distrito		mes	mes de ejec

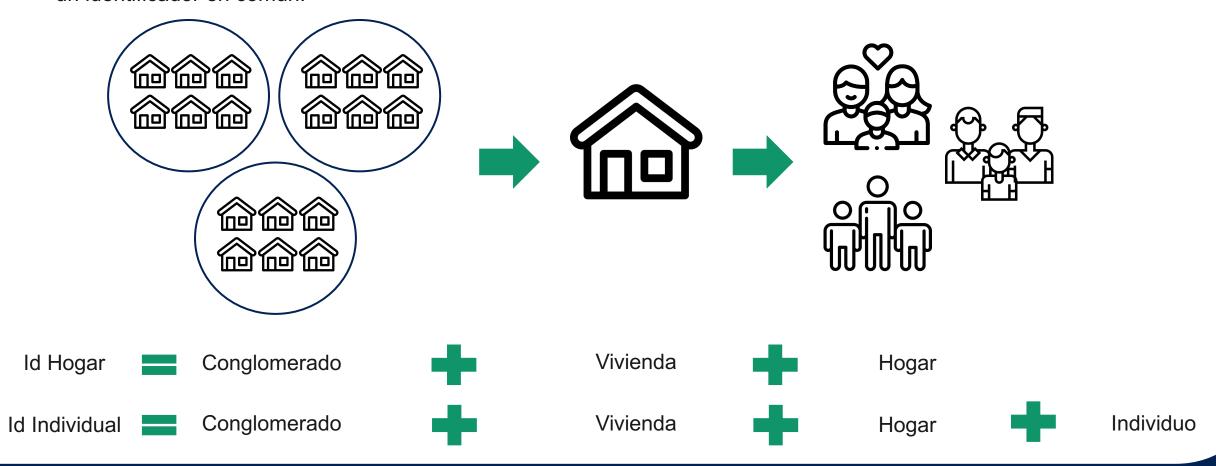


4. Explorando Variables



Identificadores de la ENAHO

En la ENAHO hay bases que están a nivel de hogar y otras que están a nivel individual. Cada una de ellas tienen un identificador en común.





Comandos para explorar variables

Comando "browse": sirve para visualizar las variables de interés en la base de datos.

```
* El comando browse
browse
browse ubigeo estrato conglome vivienda hogar codperso
```

Comando "describe": sirve para describir el formato de las variables (nombre, tipo, formato, etiqueta).

```
* El comando describe
describe
describe ubigeo estrato conglome vivienda hogar codperso p207 p208a
```

Comando "codebook": describe el contenido de la variable

* El comando codebook codebook p208a codebook ubigeo



5. Tipo y Formato de Variables



Tipo y Formato de Variables

Tipo de Variable: String

conglome	vivienda	hogar	codperso	ubigeo
005009	012	11	01	010101
005009	012	11	02	010101
005009	041	11	01	010101
005009	041	11	02	010101
005009	098	11	01	010101
005009	098	11	02	010101
005009	098	11	03	010101
005009	098	11	04	010101
005009	098	11	05	010101
005015	007	11	01	010101

Formato Variable String

format ubigeo %6s | format ubigeo %18s

ubig	jeo
	010101
	010201
	010701
	010502
	010501
	010203
	010306
	010304

Tipo y Formato de Variables

Tipo de Variable: Numérica

p207	p208a	p524a1
mujer	49	•
mujer	16	•
mujer	61	•
mujer	29	200
hombre	59	•
mujer	42	•
mujer	20	1200
hombre	18	•
mujer	16	•
mujer	36	

Variable Numérica con etiqueta

Formato Variable Numérica

format p524a1 %5.0f

|format p524a1 %5.2f ||format p524a1 %6.0fc

p524a1	
10000	
10100	
10500	
10800	
11000	
12000	
12500	
12800	

p524a1
10000.00
10100.00
10500.00
10800.00
11000.00
12000.00
12500.00
12800.00

p524a1
10,000
10,100
10,500
10,800
11,000
12,000
12,500
12,800

Tipo y Formato de Variables

Variable Numérica con etiqueta

estrato	p207
de 500 a 1 999 habitantes	mujer
de 500 a 1 999 habitantes	hombre
de 500 a 1 999 habitantes	hombre
de 500 a 1 999 habitantes	hombre
de 500 a 1 999 habitantes	mujer
de 500 a 1 999 habitantes	mujer
de 500 a 1 999 habitantes	mujer
Área de empadronamiento rural (aer) compuesto	hombre
Área de empadronamiento rural (aer) compuesto	mujer
Área de empadronamiento rural (aer) compuesto	mujer
Área de empadronamiento rural (aer) compuesto	mujer
Área de empadronamiento rural (aer) compuesto	hombre
Área de empadronamiento rural (aer) compuesto	hombre

Para saber cual es el número que le corresponde a cada etiqueta de la variable se usa el comando "label list"

```
. label list p207
p207:
1 hombre
2 mujer
```



Missing Values

Son variables numéricas con algunas observaciones que no tienen valor.

p524a1	newvar
	•
•	
200	•
1200	•
•	•
•	•
•	•
	•

El comando "mdesc" permite saber la frecuencia y el porcentaje de missing que existen en una variable.

* Missing Values
gen newvar=.
ssc install mdesc
mdesc p524a1 newvar



Variable	Missing	Total	Percent Missing
p524a1	70,290	91,315	76.98
newvar	91,315	91,315	100.00



Formato de Variables

Tipo	Almacenaje	Variable cuyo contenido es	bytes
Missing	missing	No hay valor	1
	str1	string de 1 carácter como máxima longitud	1
	str2	string de 2 caracteres como máxima longitud	2
String	str3	string de 3 caracteres como máxima longitud	3
	strn	string de n caracteres como máxima longitud	n
	byte	números enteros entre -127 y 100	1
	int	números enteros entre -32,767 y 32,740	2
Numérica	long	números enteros entre -2,147,483,647 y 2,147,482,620	4
	float	números reales con 8 dígitos de precisión	4
	double	números reales con 1/ digitos de precisión	8

En el caso de los string, n debe ser menor o igual a 244.



6. Manipulando Variables



Renombrando Variables

El comando "rename" permite cambiar de nombre a las variables.

• Renombrando la variable edad:

```
* Edad
rename p208a age
```

Renombrando la variable sexo:

```
* Sexo
rename p207 gender
```

• Renombrando grupos de variables:

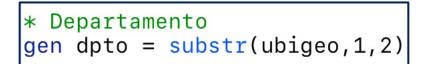
```
rename (age gender) (edad sexo)
```



El comando generate o gen

Este comando permite generar nuevas variables string o numéricas.





ubigeo	dpto
010101	01
010201	01
010701	01
010502	01
010501	01
010203	01
010306	01
010304	01
010520	01
010513	01
010114	01
010103	01
010605	01

* Edad al cuadrado
gen sq_edad=edad*edad

edad	sq_edad
49	2401
16	256
61	3721
29	841
59	3481
42	1764
20	400
18	324
16	256
36	1296
48	2304



El comando egen

Este comando permite crear nuevas variables a partir de estadísticos.

• Creamos la variable ingreso total cuyo contenido es la suma de diferentes variables:

codperso	d529t	d536	d540t	d543	ing_extra	i530a	i524a1	i538a1	i541a	ingreso
01		4063		•		7055			•	11118
02		5267		839		2786	•	•	572	9464
03	•		•			•		•	•	0

• Creamos una variable cuyo contenido sea el promedio del ingreso laboral por hogar:

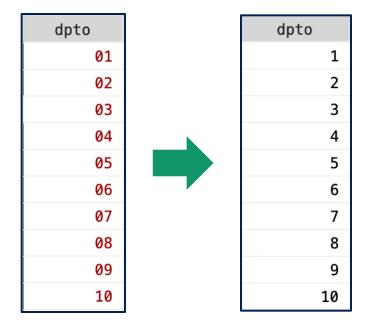
conglome	vivienda	hogar	ingreso	ingr_lab_hog
005002	011	11	63271	21821.33
005002	011	11	2193	21821.33
005002	011	11	0	21821.33
005002	023	11	32175	32175
005002	049	11	23945	8118.25
005002	049	11	0	8118.25
005002	049	11	0	8118.25
005002	049	11	8528	8118.25



Cambiando tipo de almacenaje de variables

destring: convierte variables string a variables numéricas.

destring dpto, replace



tostring: convierte variables numéricas a string.

tostring dpto, gen(str_dpto) force

dpto	str_dpto
1	1
2	2
3	3
4	4
5	5
6	6
7	7
8	8
9	9
10	10



Cambiando tipo de almacenaje de variables

encode: pasa una variable string a una variable numérica etiquetando los valores string.

encode ubigeo, gen(id_ubigeo)

ubigeo	id_ubigeo
010101	010101
021803	021803
030109	030109
040104	040104
050115	050115
060108	060108
070106	070106
080104	080104
090101	090101
100101	100101

decode: convierte variables numéricas con etiquetas en variables string.

decode dominio, gen(str_dominio)

dominio	str_dominio
sierra	sierra norte
costa c	costa centro
sierra	sierra sur
sierra	sierra sur
sierra	sierra centro
sierra	sierra norte
lima me…	lima metropolitana
sierra	sierra sur
sierra …	sierra centro
sierra …	sierra centro



7. Manipulando Observaciones



Reemplazar valores

• El comando "replace" reemplaza los valores de una variable ya creada.

Ingreso mensual

replace ingreso=ingreso/12

conglome	vivienda	hogar	codperso	ingreso
005002	011	11	01	2193
005002	011	11	03	63271
005002	011	11	02	0
005002	023	11	01	32175
005002	049	11	01	0
005002	049	11	04	23945
005002	049	11	03	8528
005002	049	11	02	0



conglome	vivienda	hogar	codperso	ingreso
005002	011	11	01	182.75
005002	011	11	03	5272.583
005002	011	11	02	0
005002	023	11	01	2681.25
005002	049	11	01	0
005002	049	11	04	1995.417
005002	049	11	03	710.6667
005002	049	11	02	0



Recodificar variables

El comando "recode" permite recodificar valores de una variable categórica y crear una nueva variable.

Primer paso: verificar la etiqueta de la variable.

Segundo paso: recodificar y crear una nueva variable

```
recode dominio (1/3=1 "Costa") (4/6=2 "Sierra") (7=3 "Selva") (8=4 "Lima Metropo<mark>litana"), gen(zona)</mark>
```



8. Borrar y Mantener Variables



El comando keep y drop

El comando "keep" mantiene las variables de interés.

* El comando keep keep pais conglome vivienda hogar codperso dpto area zona pea p204 p205 p206 /// edad sq_edad jefe mujer civil educ indigena pea peao informal ing_* ingreso /// lnwage fac500a

dpto	pais	ing_ocu_pri	ing_ocu_sec	ingreso	lnwage
1	Perú	49035	0	5272.583	8.570275
1	Perú	0	0	0	
1	Perú	2193	0	182.75	5.208119
1	Perú	17714	14461	2681.25	7.894038
1	Perú	0	0	0	
1	Perú	0	0	0	
1	Perú	8528	0	710.6667	6.566204
1	Perú	23335	0	1995.417	7.598608
1	Perú	0	0	0	
1	Perú	0	0	0	

El comando "drop" elimina las variables de interés.

pais	ingreso	lnwage
Perú	5272.583	8.570275
Perú	0	
Perú	182.75	5.208119
Perú	2681.25	7.894038
Perú	0	
Perú	0	
Perú	710.6667	6.566204
Perú	1995.417	7.598608
Perú	0	
Perú	0	



9. Ordenar Observaciones y Variables



El comando sort y gsort

El comando "sort" ordena ascendentemente

sort ingreso

conglome	vivienda	hogar	codperso	ingreso
018176	093	11	01	22771.17
015603	102	11	01	22778.58
017893	078	11	01	23715.42
007220	091	11	02	23967.92
018211	004	11	01	24961.08
005406	064	11	02	25449.5
019006	052	11	03	26155.33
008914	061	11	01	28198.33
008237	016	11	02	53323
005759	046	11	02	74092.16

El comando "gsort" ordena descendentemente

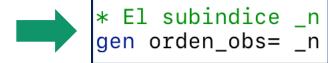
gsort -ingreso

conglome	vivienda	hogar	codperso	ingreso
005759	046	11	02	74092.16
008237	016	11	02	53323
008914	061	11	01	28198.33
019006	052	11	03	26155.33
005406	064	11	02	25449.5
018211	004	11	01	24961.08
007220	091	11	02	23967.92
017893	078	11	01	23715.42
015603	102	11	01	22778.58
018176	093	11	01	22771.17

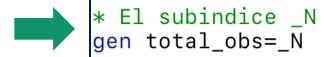


Subíndices de observaciones

 El subíndice _n: permite crear un correlativo desde la observación "1" hasta la observación "n".



• El subíndice _N: permite crear una variable con el total de observaciones de la base de datos.



conglome	vivienda	hogar	codperso	orden_obs	total_obs
005002	011	11	01	1	91315
005002	011	11	02	2	91315
005002	011	11	03	3	91315
005002	023	11	01	4	91315
005002	049	11	01	5	91315
005002	049	11	02	6	91315
005002	049	11	03	7	91315
005002	049	11	04	8	91315
005002	073	11	01	9	91315
005002	073	11	02	10	91315



El comando order

Es siempre recomendable ordenar las variables de nuestra base, tal que al inicio estén los identificadores de la unidad de observación y luego sus atributos.

order pais dpto zona area, before(conglome)

pais	dpto	zona	area	conglome
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002
Perú	1	Sierra	1	005002

order ingreso lnwage fac500a, last

ingreso	lnwage	fac500a	
182.75	5.208119	51.73801	
0		82.49285	
5272.583	8.570275	42.14626	
2681.25	7.894038	37.88447	
0		48.53986	
0		48.87992	
710.6667	6.566204	59.9916	
1995.417	7.598608	42.14626	
0		37.88447	
0		46.15303	



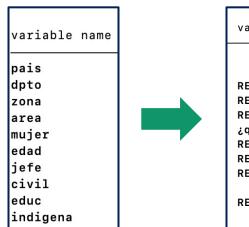
10. Etiquetas



El comando label variable

El comando "label var" permite asignar etiquetas a las variables.

```
label var pais "País"
label var dpto "Departamento"
label var zona "Zona Geográfica"
label var area "Área Geográfica"
label var mujer "Mujer"
label var edad "Edad (años)"
label var sq_edad "Edad al cuadrado"
label var jefe "Jefe de hogar"
label var civil "Estado Civil"
label var educ "Nivel educativo"
label var indigena "Indigena"
```



```
RECODE of dominio (dominio geográfico)
RECODE of estrato (estrato geográfico)
RECODE of sexo (sexo)
¿qué edad tiene en años cumplidos?
RECODE of p203 (relación de parentesco con el jefe(a) del hogar)
RECODE of p209 (¿cuál es su estado civil o conyugal?)
RECODE of p301a (¿cuál es el último año o grado de estudios y nivel que aprobó?
RECODE of p558c (por sus antepasados y de acuerdo a sus costumbres, ¿ud. se cons
```



variable label

País
Departamento
Zona Geográfica
Área Geográfica
Mujer
Edad (años)
Jefe de hogar
Estado Civil
Nivel educativo
Indigena



El comando label define

El comando "label define" permite crear el nombre de la etiqueta con sus respectivos valores.

dpto	area
1	1
1	0
2	1
2	0
3	1
3	0
4	1
4	0
5	1
5	0
6	1
6	0
7	1
8	1
8	0

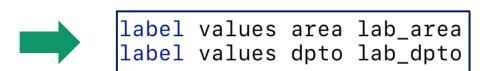
```
label define lab_area 1 "Urbano" 0 "Rural"
```

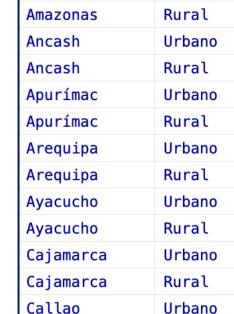
```
label define lab_dpto 1 "Amazonas" 2 "Ancash" 3 "Apurímac" 4 "Arequipa" ///
5 "Ayacucho" 6 "Cajamarca" 7 "Callao" 8 "Cusco" 9 "Huancavelica" 10 "Huánuco" ///
11 "Ica" 12 "Junín" 13 "La Libertad" 14 "Lambayeque" 15 "Lima" 16 "Loreto" ///
17 "Madre de Dios" 18 "Moquegua" 19 "Pasco" 20 "Piura" 21 "Puno" 22 "San Martín" ///
23 "Tacna" 24 "Tumbes" 25 "Ucayali"
```

El comando label values

El comando "label values" asocia la etiqueta creada en label define con una variable.

dpto	area
1	1
1	0
2	1
2	0
3	1
3	0
4	1
4	0
5	1
5	0
6	1
6	0
7	1
8	1
8	0





dpto

Amazonas

Cusco

Cusco

area

Urbano

Urbano

Rural

11. Guardar y Exportar



El comando save

Una vez que hemos hecho los cambios deseados, podemos grabar la base de datos con el comando "save".

```
* El comando save

*-----

save "base_laboral_2020.dta", replace

save "$works/base_laboral_2020.dta", replace
```





Exportar archivos

El comando "export excel" es especialmente diseñado para exportar la base en la memoria a Excel

```
* El comando export excel

*------
export excel using "$works/base_laboral_2020.xlsx", firstrow(variables) replace
export excel using "$works/base_laboral_2020.xlsx" if dpto==15, firstrow(variables) sheet("lima")
export excel using "$works/base_laboral_2020.xlsx" in 1/7, firstrow(variables) sheet("selec_in")
```

